

Klasifikasi Soal Label Gambar Soal Matematika Menggunakan Convolutional Neural Network

Fadhli Azhar¹, Kartika Fithriasari²

³Departemen Statistika, Fakultas Sains dan Analitika Data

Institut Teknologi Sepuluh Nopember

Jl. Arief Rahman Hakim, Surabaya 60111

Email: ⁽¹⁾fadhliazhar213@gmail.com, ⁽²⁾kartika_f@statistika.its.ac.id

Abstract—Pemahaman *learner-centered* merupakan pemahaman yang mendorong pelajar untuk berkontribusi secara aktif pada proses pembelajaran. Proses belajar aktif terdistribusi merupakan salah satu Teknik yang dapat diterapkan pada pemahaman *learner-centered*. Infrastruktur dalam menerapkan proses belajar aktif terdistribusi dibutuhkan agar memudahkan pelajar dalam melaksanakan proses belajar aktif terdistribusi seperti system rekomendasi. System rekomendasi yang dapat dibuat untuk membantu pengalaman belajar pelajar lebih menarik antara lain pengenalan soal, rekomendasi materi belajar dan sebagainya. System rekomendasi seperti pengenalan soal dapat dibuat dengan bantuan model deep learning seperti *Convolutional Neural Network*. Model *convolutional neural network* mampu mempelajari pola yang ada pada soal integral dan peluang. Model terbaik yang didapatkan pada hasil penerapan *convolutional neural network* adalah model *convolutional neural network* dengan 2 *convolutional kernel* dan 3 *convolutional layer*. Model tersebut mampu mendapatkan nilai kebaikan klasifikasi sebesar 0,9453 pada data training dan 0,9375 pada data testing.

Kata kunci: *Belajar Aktif Terdistribusi, Convolutional Neural Network, Learner-Centered.*

I. PENDAHULUAN

Teknologi memiliki peran yang dapat dimanfaatkan dalam pengembangan pendidikan. Teknologi yang terintegrasi dengan kurikulum akan memberikan dukungan secara langsung kepada pendidikan. Teknologi dapat membuat alat bantu belajar yang beragam sesuai dengan tujuan praktik pendidikan. Penerapan teknologi pada pendidikan dilakukan dengan penerapan prinsip *learner-centered*. Sehingga, penerapan teknologi pada pendidikan dapat membuat tipe belajar bervariasi sesuai dengan latar belakang pelajar.

Pembelajaran interaktif terdistribusi merupakan salah satu bentuk penerapan teknologi pada pendidikan. Khalifa dan Lam pada tahun 2002 menemukan bahwa pembelajaran interaktif terdistribusi lebih baik daripada pembelajaran pasif terdistribusi pada lingkungan pembelajaran berbasis web^[1]. Pembelajaran interaktif terdistribusi memberikan lingkungan belajar yang lebih mendukung pelajar. Pembelajaran interaktif terdistribusi membuat pelajar lebih aktif dan eksploratif dalam proses belajar dibandingkan pembelajaran pasif terdistribusi. Pelajar yang mengikuti pembelajaran interaktif terdistribusi mencapai nilai belajar yang lebih

tinggi daripada pelajar yang mengikuti pembelajaran pasif terdistribusi.

Salah satu teknologi yang dapat mendukung pembelajaran interaktif terdistribusi adalah system rekomendasi. Situs belajar berbasis web banyak mengembangkan system rekomendasi pada web yang digunakan. System rekomendasi yang digunakan biasanya memberikan rekomendasi materi pembelajaran selanjutnya berdasarkan pengalaman pelajar pada web. System rekomendasi juga dapat dibuat untuk membantu pelajar menyelesaikan tugas seperti pengenalan soal.

Saat ini, terdapat banyak *platform* belajar daring yang memanfaatkan teknologi untuk melakukan distribusi pembelajaran seperti Zenius, Ruangguru, Khan Academy dll. Platform belajar daring sangat mengandalkan pemahaman *learner-centered* dan Teknik pembelajaran interaktif terdistribusi dalam praktiknya. *Machine learning* dapat dimanfaatkan untuk membuat system rekomendasi yang dapat membantu pelajar dalam penggunaan *platform* belajar daring.

System rekomendasi dibuat dengan memberikan model *machine learning* beberapa data inisial sebagai inisiasi pengenalan pola. Penelitian ini akan berfokus pada pengembangan inisiasi pengenalan pembeda soal integral dan peluang. Penelitian ini dapat dikembangkan lebih lanjut dalam pembuatan API yang mampu menjadi system rekomendasi yang lebih canggih seperti system rekomendasi soal. Oleh karena itu, penelitian ini bertujuan untuk melakukan klasifikasi gambar pada dengan menggunakan metode dan *convolutional neural network*. Sumber data yang digunakan adalah data primer berupa foto SMA yang integral dan peluang.

II. TINJAUAN PUSTAKA

A. Convolutional Neural Network

Convolutional Neural Network (CNN) merupakan salah satu pengembangan dari konsep jaringan syaraf tiruan (*Neural Network*) (Wu, 2017). CNN bekerja sangat baik dalam penyelesaian kasus *computer vision*. Kasus-kasus yang diselesaikan oleh CNN adalah kasus-kasus klasifikasi dalam *image mining* seperti *image recognition*, *image classification* dll. CNN memproses data gambar dalam bentuk matriks maupun tensor yang memiliki pola tertentu. Berikut merupakan arsitektur CNN yang digambarkan secara matematis.

$$x^1 \rightarrow [w^1] \rightarrow x^2 \rightarrow \dots x^{L-1} \rightarrow [w^{L-1}] \rightarrow x^L \rightarrow [w^L] \rightarrow z$$

CNN memproses input dalam beberapa lapisan yang dinotasikan sebagai \mathbf{x} dan \mathbf{w} . \mathbf{x} adalah matriks input dan \mathbf{w} adalah matriks output. Secara proses matematis, gambar akan diproses sebagai input lalu diproses secara kolektif dan hasil pemrosesan akan digunakan untuk lapisan kedua dan seterusnya. Setelah itu, sebuah lapisan ditambahkan untuk mempelajari nilai kebaikan parameter-parameter yang digunakan dalam CNN didapatkan melalui proses *backward error propagation*. Secara matematis, sebuah strategi yang sering digunakan adalah pengodean hasil proses kolektif lapisan digunakan sebagai hasil klasifikasi. Lapisan akhir yang akan digunakan sebagai hasil klasifikasi merupakan hasil transformasi dari lapisan sebelumnya,


Proses pengklasifikasian dilakukan secara kolektif akan disebut sebagai proses alur maju. Pada proses ini, semua lapisan akan mempelajari lapisan sebelumnya yang difgunakan sebagai *input*. Hasil akhir pemrosesan kolektif lapisan akan didapatkan sebagai hasil lapisan estimasi probabilitas. Hasil lapisan estimasi probabilitas akan digunakan sebagai pengklasifikasi gambar dalam bentuk *voting*. *Voting* akan menggunakan nilai $\arg \max \mathbf{x}_i^L$

$$(\mathbf{w}^i)^{t+1} = (\mathbf{w}^i)^t - \eta \frac{\partial z}{\partial (\mathbf{w}^i)^t} \quad (1)$$

Nilai parameter yang digunakan pada CNN bertujuan untuk meminimalisir nilai kehilangan z pada *loss layer* z . Hasil klasifikasi yang digunakan akan didapatkan dengan proses yang bekerja dengan cara mempelajari lapisan secara kolektif ke belakang. Jika suatu \mathbf{x}^1 digunakan sebagai input maka proses *running* pembelajaran akan berjalan 2 arah. Pertama proses pembelajaran untuk mendapatkan hasil prediksi \mathbf{x}^L lalu pembelajaran akan dioper ke *loss layer* untuk membandingkan nilai target \mathbf{t} sesuai dengan nilai \mathbf{x}^1 . Persamaan 3 menunjukan bahwa *loss layer* yang digunakan akan membandingkan hasil pengklasifikasian dengan nilai target.

Turunan parsial $\frac{\partial z}{\partial \mathbf{w}^i}$ adalah laju peningkatkan dari nilai kehilangan z . dalam matematika optimisasi, vector turunan parsial pada persamaan 1 disebut sebagai gradien. Dalam tujuan untuk meminimalisir nilai kehilangan z , \mathbf{w}^i harus dimutakhirkan sepanjang arah berlawanan dari gradien. Turunan parsial ini melambangkan untuk perubahan dimensi \mathbf{w}^i yang berbeda. Aturan pemutakhiran ini disebut *gradient descent*.

Jika nilai gradien dipindahkan terlalu jauh maka *loss function* kemungkinan akan meningkat, oleh karena itu, pemutakhiran hanya perlu mengubah parameter-parameter melalui proporsi kecil dari gradien negatif. Hal ini dikendalikan oleh η (laju pembelajaran). Nilai $\eta > 0$ biasanya disetel angka sangat kecil. Satu pemutakhiran berdasarkan ada input \mathbf{x}^1 akan membuat nilai kehilangan lebih kecil ketika laju pembelajaran tidak terlalu besar.



Gambar 1 Arsitektur Convolutional Neural Network

Gambar 1 menunjukkan arsitektur yang digunakan oleh CNN. Arsitektur CNN memiliki beberapa lapisan penyusun, yaitu *convolutional layer*, *ReLU layer*, *pooling layer*, dan *fully connected layer*. *Convolutional layer*, *pooling layer*, dan *ReLU layer* merupakan lapisan yang melakukan fitur ekstraksi. *Fully connected layer* merupakan lapisan yang melakukan pengklasifikasian untuk menghasilkan hasil klasifikasi berdasarkan fitur ekstraksi.

B. Evaluasi Hasil Klasifikasi

Evaluasi hasil klasifikasi adalah alat pengukuran yang digunakan untuk menilai hasil pengklasifikasi (Han dkk., 2012). Ada dua jenis tipe kasus yang harus dicermati ketika mengevaluasi hasil klasifikasi, yaitu data *balance* dan data *imbalance*. Data *balance* bisa diukur menggunakan akurasi. Data *imbalance* diukur menggunakan sensitivity, specificity, precision, nilai ukuran F .

Evaluasi hasil klasifikasi akan menilai pengklasifikasi dengan data yang memiliki hasil sebagai berikut.

1. **True positif** adalah data yang *positive* dinilai benar *positive* oleh pengklasifikasi.
2. **True negatif** adalah data yang *negative* dinilai benar *negative* oleh pengklasifikasi.
3. **False positive** adalah data yang *negative* yang dinilai salah *positive* oleh pengklasifikasi.
4. **False negative** adalah data yang *negative* yang dinilai salah *positive* oleh pengklasifikasi.

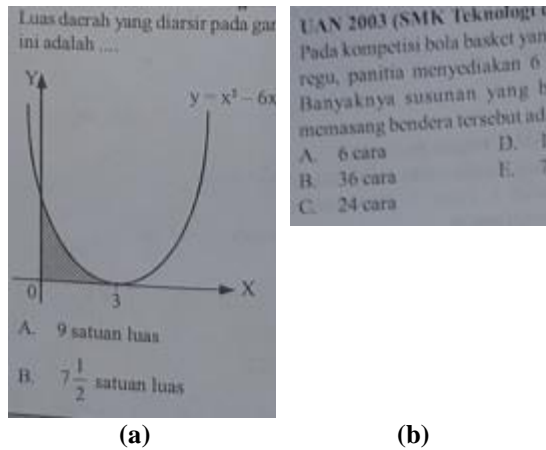
Akurasi adalah alat pengukuran evaluasi klasifikasi yang menilai data yang benar dinilai oleh pengklasifikasi. Dalam kasus pengenalan pola, akurasi dikenal dengan sebutan laju pengenalan. Akurasi akan mengukur *true positive* dan *true negative* dibandingkan dengan total data. Berikut merupakan rumus yang digunakan untuk menghitung akurasi.

$$\text{accuracy} = \frac{\text{True Positive} + \text{True Negative}}{\text{Total Data yang Digunakan}} \quad (2)$$

III. METODOLOGI PENELITIAN

A. Sumber Data

Data yang digunakan pada penelitian tugas akhir ini adalah data primer, yaitu gambar yang didapat melalui smartphone Samsung note10+ dengan file berformat jpeg. Gambar akan diekstraksi menjadi warna hitam putih. Foto yang digunakan akan memiliki gambar dan peluang. Berikut merupakan contoh gambar soal yang akan digunakan pada penelitian ini.



Gambar 2 (a). Contoh soal Integral **(b)** Contoh soal peluang

B. Variabel Penelitian

Variabel yang akan digunakan merupakan ekstraksi fitur pixel pada gambar dengan warna hitam putih.

Tabel 1. Variabel penelitian yang digunakan

Variabel	Keterangan	Skala	Nilai
X	Nilai Ekstraksi warna	Interval	0-255
Y	Label gambar soal	Nominal	Integral dan peluang

Variabel X merupakan nilai ekstraksi warna foto yang digunakan. nilai ekstraksi warna foto memiliki skala interval dengan interval 0-255. Variabel Y merupakan label foto. Label foto memiliki skala nominal dengan 2 label, yaitu label integral dan label peluang. Berikut merupakan struktur data yang akan digunakan pada penelitian kali ini.

Tabel 2. Struktur data

Gambar ke-	No.	X_1	X_2	...	X_{500}	Y
1	1.	$X_{1,1}$	$X_{1,2}$...	$X_{1,500}$	Y_1
	2.	$X_{2,1}$	$X_{2,2}$...	$X_{2,500}$	
	
	500	$X_{500,1}$	$X_{500,2}$...	$X_{500,500}$	
2	501	$X_{501,1}$	$X_{501,2}$...	$X_{501,500}$	Y_2
	502	$X_{502,1}$	$X_{502,2}$...	$X_{502,500}$	
	
	1000	$X_{1000,1}$	$X_{1000,2}$...	$X_{1000,500}$	
...
160	79840	$X_{79841,1}$	$X_{79841,2}$...	$X_{79840,500}$	Y_{160}
	79841	$X_{79842,1}$	$X_{79842,2}$...	$X_{79841,500}$	
	
	80000	$X_{80000,1}$	$X_{80000,2}$...	$X_{80000,500}$	

Jumlah foto yang digunakan sebanyak 160 foto dengan ukuran pixel 500x500 sehingga didapatkan 80000x500 fitur yang akan digunakan sebagai data input. Variabel X_1 merupakan fitur ke-1 dan $X_{1,1}$ merupakan nilai pixel yang didapatkan dari fitur ekstraksi. Y_1 merupakan label ke-1 yang digunakan dalam data.

B. Langkah Penelitian

Langkah penelitian yang akan digunakan dalam penelitian tugas akhir ini adalah sebagai berikut.


1. Melakukan studi literatur dan referensi terkait topik dan metode dalam penelitian.
2. Mengumpulkan data dengan memfoto.

3. Melakukan pre-processing data sebagai berikut.
 - a. Melakukan ekstraksi data gambar.
 - b. Mengubah gambar menjadi warna hitam putih.
 - c. Mengubah ukuran pixel gambar menjadi 500x500.
4. Mengulangi Langkah 3a hingga 3c pada semua gambar yang digunakan.
5. Membuat gambaran umum data gambar.
6. Melakukan klasifikasi soal integral dan peluang.
7. Menghitung nilai kebaikan hasil klasifikasi.
8. Memberikan kesimpulan dan saran berdasarkan hasil penelitian.

IV. HASIL DAN PEMBAHASAN

C. Preprocessing Data Foto Soal

Pada penelitian ini, tahap preprocessing yang dilakukan adalah mengubah warna pada fitur ekstraksi yang digunakan menjadi berwarna hitam putih. Berikut merupakan salah satu contoh fitur ekstraksi yang sudah diubah menjadi berwarna hitam putih.



Gambar 3. (a) Foto soal sebelum preprocessing **(b)** Foto soal setelah preprocessing


Pada proses preprocessing, foto soal diubah menjadi berwarna hitam putih dan ukuran pixel diubah menjadi 500x500. Tahap preprocessing dilakukan pada semua data foto yang digunakan sehingga data input yang didapatkan sebesar 80000x500 fitur dengan 2 label, yaitu label integral dan label peluang. Berikut merupakan matriks data ke-1 yang sudah diubah dari berwarna menjadi hitam putih.

$$\begin{pmatrix} 254 & 253 & 255 \\ \vdots & \vdots & \vdots \\ 251 & 253 & 254 \\ 254 & 254 & 255 \\ \vdots & \vdots & \vdots \\ 251 & 253 & 254 \\ 253 & 252 & 254 \\ \vdots & \vdots & \vdots \\ 251 & 253 & 254 \end{pmatrix} \quad \begin{pmatrix} 254 & 251 & 253 \\ \vdots & \vdots & \vdots \\ 253 & 253 & 253 \end{pmatrix}$$

Gambar 4. (a) Matriks RGB sebelum praproses **(b)** Matriks RGB setelah praproses


A. Deskripsi Data hasil Preprocessing

Data yang didapat dari *preprocessing* adalah data hasil *feature extraction* berwarna hitam putih dengan ukuran pixel 500x500. Nilai *feature* ekstraksi yang semakin besar menunjukkan bahwa warna pada gambar yang dilakukan fitur ekstraksi semakin putih. Nilai fitur ekstraksi yang semakin kecil menunjukkan bahwa warna pada gambar yang dilakukan fitur ekstraksi semakin hitam. Label yang digunakan sebanyak 2 label, yaitu label bergambar dan label tidak bergambar. Jumlah label yang digunakan sebanyak 80 label integral dan 80 label peluang. Berikut merupakan contoh gambar soal integral.



Gambar 5. contoh soal integral

Gambar 5 menunjukkan bahwa gambar soal integral memiliki beberapa karakteristik. Soal integral memiliki gambar seperti yang ditunjukkan pada kurva garis, memiliki persamaan, memiliki simbol dan teks. Karakteristik tersebut akan digunakan untuk menunjukkan kekhasan gambar soal integral saat membentuk model. Berikut merupakan contoh soal peluang.




Gambar 6. Contoh soal peluang

Gambar 6 menunjukkan contoh soal peluang. Karakteristik soal peluang hanya memiliki teks yang disusun oleh huruf dan angka saja. Karakteristik tersebut akan digunakan untuk menjadi ciri khas gambar soal peluang dalam pemodelan.

B. Klasifikasi Gambar Soal Menggunakan CNN

Setelah melakukan preprocessing data pada setiap feature yang digunakan, akan dilakukan pengklasifikasian gambar soal integral dan peluang dengan menggunakan metode Convolutional Neural Network (CNN). Jumlah convolution kernel yang digunakan pada tahap ini sejumlah 2,3,4,5,6, dan 7 convolutional kernel size dengan masing-masing convolutional layer maksimal 3 convolutional layer. Berikut merupakan contoh arsitektur CNN yang digunakan dalam penelitian ini.



Gambar 7. Contoh arsitektur CNN

Gambar 7 menunjukkan contoh visualisasi arsitektur CNN yang digunakan dalam penelitian ini. Arsitektur yang dijadikan contoh pada gambar 4.4 adalah arsitektur dengan 2 *Convolutional kernel* dan 3 *convolutional layer*. Berikut merupakan contoh perhitungan matriks konvolusi pada penelitian ini.

$$\begin{pmatrix} 254 & 251 & \dots & 253 \\ \vdots & \vdots & \ddots & \vdots \\ 253 & 253 & \dots & 253 \end{pmatrix} \quad \begin{pmatrix} 1 & 0 & -1 \\ 2 & 0 & -2 \\ 1 & 0 & -1 \end{pmatrix}$$

(a) (b)

$$\begin{pmatrix} 6 & -6 & \dots & -1 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 0 \end{pmatrix}$$

(c)

Gambar 8. (a) Matriks konvolusi (b) matriks kernel konvolusi (c) Matriks konvolusi terbaru

Gambar 8 (a) merupakan matriks konvolusi yang digunakan sebagai input pada penelitian ini. Matriks kernel konvolusi pada gambar 8 (b) merupakan salah satu matriks penciri yang digunakan dalam penelitian ini. Matriks konvolusi akan dikalikan dengan matriks kernel konvolusi sehingga menghasilkan matriks konvolusi terbaru pada gambar 4.5 (c). berikut merupakan gambaran pada proses matriks ReLU.

$$\begin{pmatrix} 6 & -6 & \dots & -1 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 0 \end{pmatrix} \quad \begin{pmatrix} 6 & 0 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 0 \end{pmatrix}$$

(a) (b)

Gambar 9. (a) matriks konvolusi (b) matriks ReLU


Gambar 9 merupakan gambar yang menunjukkan proses perubahan dari matriks konvolusi menjadi matriks ReLU. Pada gambar 9 (a) masih terdapat nilai negative seperti -6 dan -1. Gambar 9 (b) menunjukkan bahwa matriks konvolusi sudah diubah menjadi matriks ReLU karena sudah tidak memiliki nilai negatif. Berikut merupakan ilustrasi dari perubahan matriks ReLU menjadi matriks *pooling* menggunakan *max pooling*.

$$\begin{pmatrix} 6 & 0 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & 0 \end{pmatrix} \quad \begin{pmatrix} 6 & 0 & 5 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & 0 \end{pmatrix}$$

(a) (b)

Gambar 10 (a) matriks ReLU (b) matriks konvolusi terbaru

Gambar 10 (a) menunjukkan matriks ReLU yang didapatkan dari proses ReLU. Gambar 10 (b) menunjukkan bahwa matriks ReLU sudah diubah menjadi matriks konvolusi terbaru menggunakan metode *max pooling*. Matriks tersebut akan digunakan pada tahapan selanjutnya dalam proses *neural network*. Berikut merupakan bentuk visualisasi pencirian yang terjadi pada gambar yang digunakan pada penelitian ini.



Gambar 11 Proses pencirian pada salah gambar. Berikut pembahasan lebih lanjut untuk masing-masing model yang dibentuk dari arsitektur.

a. Klasifikasi Gambar Soal menggunakan CNN dengan 2 convolutional kernel

Berikut merupakan tabel hasil klasifikasi model CNN dengan 2 *convolutional kernel* pada arsitektur CNN dengan maksimal 3 *convolutional layer*.

Tabel 3. Hasil kebaikan klasifikasi pada data training dan testing menggunakan 2 convolutional kernel

No.	Convolutional Layer	Akurasi	
		Training	Testing
1.	1	0,5000	0,5000
2.	2	0,9375	0,8125
3.	3	0,9453	0,9375

Tabel 3 menunjukkan hasil kebaikan klasifikasi model CNN dengan 2 *convolutional kernel* pada arsitektur CNN dengan maksimal 3 *convolutional layer*. Pada model-model tersebut, didapatkan bahwa model CNN dengan 2 *convolutional kernel* dan 3 *convolutional layer* merupakan model terbaik dengan nilai akurasi pada data training dan testing masing-masing sebesar 0,9453 dan 0,9375.

b. Klasifikasi Gambar Soal menggunakan CNN dengan 3 convolutional kernel

Berikut merupakan tabel hasil klasifikasi model CNN dengan 3 *convolutional kernel* pada arsitektur CNN dengan maksimal 3 *convolutional layer*.

Tabel 4. Hasil kebaikan klasifikasi pada data training dan testing menggunakan 3 convolutional kernel

No.	Convolutional Layer	Akurasi	
		Training	Testing
1.	1	0,7188	0,5000
2.	2	0,5156	0,7500
3.	3	0,8750	0,6875

Tabel 4 menunjukkan bahwa nilai hasil kebaikan klasifikasi pada model CNN dengan 3 *convolutional kernel* pada arsitektur dengan maksimal 3 *convolutional layer* mendapatkan nilai akurasi pada data training dan testing masing-masing sebesar 0,7188 dan 0,5000 pada arsitektur dengan 1 *convolutional layer*. Model CNN 3 *convolutional kernel* dengan 2 *convolutional layer* mendapatkan hasil kebaikan klasifikasi sebesar 0,5156 pada data training dan 0,7500 pada data testing. Sedangkan model CNN 3 *convolutional kernel* dengan 3 *convolutional layer* mendapatkan nilai hasil kebaikan klasifikasi sebesar 0,8750 pada data training dan 0,6875 pada data testing.

c. Klasifikasi Gambar Soal menggunakan CNN dengan 4 convolutional kernel

Berikut merupakan tabel hasil klasifikasi model CNN pada data soal integral dan peluang dengan 4 *convolutional kernel* pada arsitektur maksimal 3 *convolutional layer*.

Tabel 5. Hasil kebaikan klasifikasi pada data training dan testing menggunakan 4 convolutional kernel

No.	Convolutional Layer	Akurasi	
		Training	Testing
1.	1	0,6172	0,7812
2.	2	0,6406	0,5000
3.	3	0,5391	0,5000

Tabel 5 menunjukkan nilai hasil kebaikan klasifikasi model CNN dengan 4 *convolutional kernel* pada arsitektur maksimal 3 *convolutional layer*. Model CNN 4 *convolutional kernel* dengan 1 *convolutional layer* mendapatkan hasil kebaikan klasifikasi pada data training

dan testing masing-masing sebesar 0,6172 dan 0,7812. Model CNN dengan 4 *convolutional kernel* dengan 2 *convolutional layer* mendapatkan hasil kebaikan klasifikasi pada data training dan data testing masing-masing sebesar 0,6406 dan 0,5000. Model CNN dengan 4 *convolutional kernel* dengan 3 *convolutional layer* mendapatkan hasil klasifikasi pada data training dan testing masing-masing sebesar 0,5391 dan 0,5000. Model CNN terbaik pada data training didapatkan oleh model CNN 4 *convolutional kernel* dengan 2 *convolutional layer* dan model CNN terbaik pada data testing didapatkan oleh model CNN dengan 4 *convolutional kernel* dengan 1 *convolutional layer*.

d. Klasifikasi Gambar Soal menggunakan CNN dengan 5 convolutional kernel

Berikut merupakan hasil kebaikan klasifikasi model CNN dengan 5 *convolutional kernel* dengan maksimal 3 *convolutional layer* pada data soal integral dan peluang.

Tabel 6. Hasil kebaikan klasifikasi pada data training dan testing menggunakan 5 convolutional kernel

No.	Convolutional Layer	Akurasi	
		Training	Testing
1.	1	0,7031	0,5312
2.	2	0,5000	0,5000
3.	3	0,8047	0,5000

Tabel 6 menunjukkan hasil kebaikan klasifikasi pada data training dan data testing soal integral dan peluang menggunakan 5 *convolutional kernel* dengan maksimal 3 *convolutional layer*. Model CNN terbaik yang didapatkan pada pengklasifikasian data training adalah model CNN menggunakan 5 *convolutional kernel* dengan 3 *convolutional layer* yang mendapatkan nilai akurasi 0,8047. Model CNN terbaik yang mengklasifikasi data testing adalah model CNN menggunakan 5 *convolutional kernel* dengan 1 *convolutional layer*.

e. Klasifikasi Gambar Soal menggunakan CNN dengan 6 convolutional kernel

Berikut merupakan tabel nilai hasil kebaikan klasifikasi model CNN menggunakan 6 *convolutional kernel* dengan maksimal menggunakan 3 *convolutional layer* pada data soal integral dan peluang.

Tabel 7. Hasil kebaikan klasifikasi pada data training dan testing menggunakan 6 convolutional kernel

No.	Convolutional Layer	Akurasi	
		Training	Testing
1.	1	0,6406	0,7500
2.	2	0,5000	0,5000
3.	3	0,8984	0,8125

Tabel 7 menunjukkan nilai hasil kebaikan klasifikasi pada data training dan testing menggunakan 6 *convolutional kernel* dengan maksimal 3 *convolutional layer*. Model terbaik pada pengklasifikasian data training dan data testing didapatkan oleh model CNN dengan 6 *convolutional kernel* dengan 3 *convolutional layer* dengan nilai akurasi sebesar 0,8984 untuk data training dan 0,8125 untuk data testing.

f. Klasifikasi Gambar Soal menggunakan CNN dengan 7 convolutional kernel

Berikut merupakan tabel hasil kebaikan klasifikasi model CNN dengan 7 *convolutional kernel* dengan maksimal 3 *convolutional layer* pada data soal integral dan peluang.

Tabel 8. Hasil kebaikan klasifikasi pada data training dan testing menggunakan 7 convolutional kernel

No.	Convolutional Layer	Akurasi	
		Training	Testing
1.	1	0,5000	0,5000
2.	2	0,5781	0,8750
3.	3	0,5000	0,5625

Tabel 8 menunjukkan bahwanilai hasil kebaikan klasifikasi model CNN dengan 7 *convolutional kernel* terbaik didapatkan oleh model dengan arsitektur 2 *convolutional layer* yang medapatkan nilai kebaikan pada data training sebesar 0,5781 dan nilai kebaikan hasil klasifikasi pada data testing sebesar 0,8750.

C. Perbandingan Performa Klasifikasi Setiap Convolutional Kernel

Setelah dilakukan pengklasifikasian menggunakan model *Convolutional Neural Network* dengan jumlah *convolution kernel* sejumlah 2,3,4,5,6 dan 7 dalam jumlah *convolutional layer* sejumlah maksimal 3 dan didapatkan nilai kebaikan klasifikasi berupa akurasi pada masing-masing model CNN maka akan dilakukan perbandingan model untuk mendapatkan model terbaik. Berikut merupakan tabel perbandingan performansi model CNN.

Tabel 9. Perbandingan performansi model CNN

No .	Convolutio nal Kernel	Convolutio nal layer	Akurasi	
			Traini ng	Testin g
1.	2	3	0,9453	0,9375
2.	3	3	0,8750	0,6875
3.	4	1	0,6172	0,7812
4.	5	3	0,8047	0,5000
5.	6	3	0,8984	0,8125
6.	7	2	0,5781	0,8750

Tabel 9 menunjukkan bahwa model *convolutional neural network* dengan *convolution kernel* dan *convolutional layer* masing-masing sebanyak 2 dan 3 merupakan model terbaik pada data *training* dan *testing* dengan nilai akurasi masing-masing 0,9453 dan 0,9375.

V. KESIMPULAN DAN SARAN

A. Kesimpulan

Berdasarkan hasil dan pembahasan didapatkan beberapa kesimpulan yang dapat ditarik sebagai berikut.

1. Fitur ekstraksi data integral dan peluang merupakan gambar yang hamper mirip karena memiliki nilai rata-rata fitur masing-masing pada titik 177 dan 176 dengan median 152 dan 154.
2. Model terbaik pada *convolutional kernel* 2 adalah model CNN dengan 3 *convolutional layer*, Model terbaik pada *convolutional kernel* 3 adalah model CNN dengan 3 *convolutional layer*, Model terbaik pada *convolutional kernel* 4 adalah model CNN

dengan 1 *convolutional layer*, Model terbaik pada *convolutional kernel* 5 adalah model CNN dengan 3 *convolutional layer*, Model terbaik pada *convolutional kernel* 6 adalah model CNN dengan 3 *convolutional layer*, Model terbaik pada *convolutional kernel* 7 adalah model CNN dengan 2 *convolutional layer*.

3. Model CNN terbaik yang didapatkan dari penelitian ini adalah model CCN dengan *convolutional kernel* 2 dan 3 *convolutional layer* dengan nilai akurasi 0,9453 dan 0,9375 pada data training dan data testing.

B. Saran

Berdasarkan kesimpulan yang diperoleh, berikut saran yang dipertimbangkan untuk penelitian selanjutnya.

1. Menambah jumlah data dan variasi data yang digunakan agar mendapatkan hasil yang lebih baik karena dengan jumlah data dan variasi data yang banyak dapat membuat model dapat mendeteksi pola yag lebih kompleks.
2. Mencoba menggunakan metode klasifikasi yang lain dan menjadikan model yang didapatkan pada penelitian ini sebagai pembanding.

DAFTAR PUSTAKA

- [1] Bo Gao dan Michael W Spratling. (2021). *Robust via Hierarchical Convolutional Features from a Shape Biased CNN*. Department of Informatics, King's College London, London, UK.
- [2] Greg Pass dan Ramin Zabih. (1996). *Histogram Refinement for Content Based Image Retrieval*. Computer Science, Cornell University, Ithaca, New York.
- [3] Ignacio Rocco, Relja Arandjelovic, dan Josef Sivic. (2017). *Convolutional Neural Network for Geometric Matching*. CVF.
- [4] Jianxin Wu. (2017). *Introduction to Convolutional Neural Network*. Lamda Group.
- [5] Jiawei Han, Michael Kamber, dan Jian Pei. (2012). *Data Mining Concept and Technique*. Morgan Kaufmann
- [6] Keiron O'Shea dan Ryan Nash. (2015). *An Introduction to Convolutional Neural Network*. arXiv:1511.98458v2 [cs.NE]
- [7] Beibei Huo, Guxia Kang, Kui Liu, dan Ningbo Zhang. (2018). *Breast Cancer Classification Based on Fully Connected Layer First Convolutional Neural Network*. IEEE.
- [8] Lilei Sun, Huijie Sun, Junqian Wang, Shuai Wu, Yong Zhao, dan Yong Xu. (2021). *Breast Mass Detection in Mammography Based on Image and CNN*. MDPI

- [9] McCombs dan Barbara L.(2000). *Assessing the Role of Educational Technology in the Teaching and Learning Porcess: A Learner-Centered Perspective*. Eric.
- [10] Michael Ryan dan Novita Hanifah. (2015). *An Examination of Character Recognition on ID Card Using Approach*. ICCSCI 2015.
- [11] Mohamed Khalifa dan Rinky Lam. (2002). *Web-Based Learning : Effects on Learning Process and Outcome*. IEEE.
- [12] Wenli Yang, Shuangshuang Fan, Shuxiang Xu, Peter King, Byeong Kang, dan Eonjoo Kim. (2019). *Autonomous Underwater Vehicle Navigation Using Sonar Image Matching based on Convolutional Neural Network*. IFAC.